

Générateur de données CSV fictives

Outil web de génération de datasets synthétiques cohérents, sans API ou assisté par Gemini

1. Contexte et problématique

En data analytics, l'accès aux données réelles est souvent le principal goulet d'étranglement. Contraintes réglementaires (RGPD), confidentialités des données clients, délais d'habilitation : autant de freins qui empêchent de démarrer une analyse, de tester un pipeline ou d'entraîner un modèle. L'alternative classique, construire manuellement un dataset fictif sous Excel, est chronophage, peu réaliste et difficile à adapter.

Ce projet répond à ce problème en proposant un générateur de données CSV fictives, accessible directement depuis un navigateur. Deux modes de génération sont disponibles : un mode entièrement local sans aucune clé API, et un mode assisté par l'IA Gemini Flash de Google (clé gratuite). L'utilisateur sélectionne un secteur d'activité, un thème, un volume de lignes et obtient en quelques secondes un fichier CSV cohérent et prêt à l'emploi.

2. Architecture et modes de fonctionnement

L'outil est une interface web single-page (HTML, CSS, JavaScript) qui s'exécute entièrement côté client, sans aucun serveur. Deux modes sont accessibles via un sélecteur en haut du formulaire.

Mode	Accès	Principe	Limite
Sans API	100 % gratuit	Génération locale par templates métiers prédéterminé par secteur	500 lignes max, 6 colonnes max
Gemini Flash	Clé gratuite Google AI Studio	Génération par IA : colonnes et valeurs adaptées au secteur et aux thèmes	lignes max

En mode Sans API, les données sont générées instantanément à partir de templates métiers intégrés couvrant 12 secteurs. En mode Gemini, le prompt est construit dynamiquement à partir des choix de l'utilisateur et envoyé à l'API Google AI Studio. Dans les deux cas, le fichier CSV est proposé au téléchargement sans aucun traitement serveur.

3. Fonctionnalités et paramètres

Le formulaire expose l'ensemble des paramètres de génération. Chaque option est accessible via un menu déroulant, une case à cocher ou un champ libre.

Paramètre	Description	Valeurs possibles
Mode de génération	Choisit entre génération locale ou IA Gemini	Sans API (gratuit), Gemini (clé gratuite)

Secteur d'activité	Définit le contexte métier des données	Banque, Telecom, Retail, Santé, RH, Jeux video, Assurance, Immobilier, Transport, Marketing, Education, Energie
Thèmes spécifiques	Affine les colonnes générées (mode Gemini)	Libre — ex. : churn, mobile, abonnements
Nombre de colonnes	Contrôle la richesse du dataset	3 à 8 (max 6 en mode Sans API)
Nombre de lignes	Volume du fichier construit	10 à 500 (Sans API), 10 à 2 000 (Gemini)
Séparateur CSV	Format de sortie du fichier	Virgule, point-virgule, tabulation
Valeurs nulles	Simule des données imparfaites réalistes	Case à cocher · ~3 % de chance par cellule
Doublons	Simule des erreurs de saisie	Case à cocher · ~1 % de lignes dupliquées
Headers anglais	Langue des noms de colonnes	Case à cocher · Nom de colonne anglais ou français
Nom du fichier	Nom du fichier telecharge	Champ libre — .csv ajoute automatiquement

4. Cas d'usage

Le générateur couvre quatre grandes situations. En amont d'un projet analytique, il permet de démarrer l'exploration et la modélisation sans attendre l'habilitation aux données réelles. En phase de développement, il alimente les pipelines de traitement pour valider la logique de nettoyage et de transformation. En formation, il fournit des jeux de données réalistes et variés pour les exercices pratiques. Enfin, en démo ou dans les présentations, il permet d'illustrer des analyses sans exposer de données sensibles.

5. Choix techniques et limites

Le mode Sans API est instantané et ne requiert aucune configuration, mais les données reposent sur des templates fixes, les colonnes et valeurs sont prédéterminées par secteur et ne s'adaptent pas à un thème spécifique. Le mode Gemini produit des données beaucoup plus cohérentes avec le thème saisi, mais dépend d'une clé API Google AI Studio (obtention gratuite en quelques minutes sur aistudio.google.com).

Dans les deux cas, l'architecture entièrement côté client garantit la simplicité du déploiement et l'absence de serveur à maintenir. Les données générées sont fictives et ne constituent pas un substitut aux données réelles pour la validation finale d'un modèle en production. Elles sont en revanche

suffisamment réalistes pour la phase de développement, et leur cohérence interne est garantie par les templates métiers ou par l'intelligence du modèle de langage sous-jacent.