
Modèle prédictif de l'attrition client

Identification des profils à risque et leviers de rétention · Secteur bancaire

1. Contexte et problématique

Dans le secteur bancaire, la rétention client est un enjeu stratégique de première ordre. La conquête d'un nouveau client coûte en moyenne cinq à sept fois plus cher que la fidélisation d'un client existant. Pourtant, la grande majorité des établissements financiers ne dispose pas d'un système capable d'anticiper le départ d'un client avant qu'il ne ferme son compte ou transfère ses avoirs vers la concurrence. C'est précisément ce problème que ce projet cherche à résoudre.

J'ai travaillé sur un dataset bancaire réel composé de plusieurs milliers d'observations clients, avec pour objectif de construire un modèle capable de prédire la probabilité qu'un client quitte son établissement bancaire. Chaque ligne représente un client et ses caractéristiques : ancienneté, nombre de produits détenus, activité sur le compte, score de crédit, tranche d'âge et données démographiques. La variable cible, binaire, indique si le client a effectivement résilié, c'est ce que l'on appelle le churn, ou attrition.

Dans un contexte comme celui du Crédit Agricole, où la relation client est au cœur du modèle mutualiste, anticiper ces départs permettrait aux conseillers d'agir en amont, avant que la décision du client ne soit irréversible. L'enjeu n'est donc pas seulement technique, c'est une question de posture commerciale et de qualité de service.

2. Démarche analytique et réflexion fil rouge

Avant d'entraîner le moindre algorithme, j'ai consacré une part significative du projet à la préparation et à la compréhension des données. Cette étape, souvent sous-estimée, est pourtant celle qui conditionne entièrement la fiabilité du modèle final. J'ai commencé par une analyse exploratoire complète : distribution des variables, détection des valeurs manquantes, identification des corrélations et des déséquilibres de classes. On observe notamment que les clients qui résilient représentent une minorité de l'échantillon, un déséquilibre que l'on retrouve systématiquement dans les problématiques de churn réelles.

J'ai ensuite procédé à l'encodage des variables catégorielles, à la normalisation des variables numériques et à la séparation du dataset en deux sous-ensembles : 80 % pour l'entraînement, 20 % pour le test. Cette séparation est fondamentale, elle permet d'évaluer les performances du modèle

Sur des données qu'il n'a jamais vues, ce qui garantit une estimation honnête de sa capacité à se généraliser.

J'ai testé plusieurs algorithmes de classification, Régression Logistique, Décision Tree, SVC Linéaire et Random Forest, en comparant leurs performances sur les métriques clés. Le Random Forest s'est imposé comme le modèle le plus performant, avec une accuracy de 95,2 % et un F1-Score de 90 % sur la classe positive. Pour aller plus loin, j'ai également intégré VADER Sentiment comme variable explicative supplémentaire, en faisant l'hypothèse que la tonalité des interactions textuelles avec la banque pouvait être un signal prédicteur du churn. Le tableau ci-dessous résume les performances comparatives des modèles testés.

Modèle	Accuracy	Precision	Recall	F1-Score
Random Forest	95,2 %	91 %	90 %	90 %
SVC Linéaire	90,5 %	87,5 %	87,5 %	87,5 %
Decision Tree	85,7 %	80 %	80 %	80 %
Régression Log.	61,9 %	20 %	20 %	20 %

L'analyse des variables d'importance du Random Forest révèle que l'âge du client, son niveau d'activité sur le compte et le nombre de produits détenus sont les trois facteurs les plus prédictifs de l'attrition. Un client peu actif, mono-produit et dont l'ancienneté dépasse un certain seuil sans évolution de son équipement bancaire présente un profil à risque significativement plus élevé que la moyenne.

3. Applications métier et leviers d'action

Les résultats de ce modèle ne sont utiles que s'ils se traduisent en actions concrètes. *Un modèle de prédiction du churn n'est pas une fin en soi, c'est un outil d'aide à la décision au service des équipes commerciales et CRM.*

Appliqué au Crédit Agricole, ce modèle permettrait de générer chaque mois une liste de clients à risque, segmentée par niveau de probabilité de départ. Les conseillers d'agence pourraient alors prioriser leurs relances sur les profils identifiés comme critiques, avec un argumentaire personnalisé basé sur les variables qui contribuent le plus à leur score de risque. Un client peu équipé et peu actif n'a pas besoin du même discours qu'un client multi-produits dont l'activité a chuté récemment.

Au niveau du pilotage, ce type de modèle offre également un indicateur avancé de la santé du portefeuille : si la proportion de clients à risque augmente d'un trimestre à l'autre, cela peut signaler une dégradation de la satisfaction ou une pression concurrentielle plus forte sur certains segments.

C'est une information stratégique qui dépasse la simple opération de fidélisation et entre dans le pilotage de l'expérience client à l'échelle de l'établissement.

À terme, ce modèle pourrait être intégré dans le système CRM existant, avec une mise à jour mensuelle du scoring et un tableau de bord dédié aux responsables d'agence. L'objectif final : réduire le taux d'attrition de plusieurs points de pourcentage, ce qui, à l'échelle d'un portefeuille de plusieurs centaines de milliers de clients, représente un impact financier et relationnel considérable.