TP : La Régression Logistique avec R

Pour illustrer la réalisation d'une régression logistique, nous allons utiliser le jeu de données **heart_disease**. Ce dataset contient les données de 303 patients inclus dans un essai clinique dans le domaine de la cardiologie.
Treize variables sont mesurées, comme l'âge, le sexe, le niveau de douleur de la poitrine, etc... La présence ou l'absence d'une pathologie cardiaque est renseignée dans la variable has_heart_disease ("no" pour l'absence de pathologie, "yes" pour la présence).

Partie 1 : Importation et connaissance des données

Dans un premier temps, on va installer dans R les packages nécessaires pour les visualisations ainsi que celui où l'on va retrouver nos données.

```
install.packages(c("car", "tidyverse", "funModeling", "finalfit", "knitr"))
```

Consignes :

1. Chargez les librairies.
2. Chargez le jeu de données *heart_disease*.

```
# Chargement des librairies
library(car)
library(tidyverse)
library(funModeling)

# Chargement des données
data(heart_disease)

# Vérifier la bonne importation
head(heart_disease)

# Quelle est la dimension de notre dataset ?
dim(heart_disease)
```

Question : Quelle est la dimension de notre dataframe?

- 6 lignes et 13 colonnes
- 13 colonnes et 6 lignes
- 303 lignes et 16 colonnes
- 303 colonnes et 16 lignes ?

Dans cet exemple, nous allons chercher à évaluer si deux variables (la fréquence cardiaque maximale max_heart_rate et le sexe gender) sont significativement liées à la présence d'une pathologie cardiaque, et si c'est le cas, à caractériser ces relations.

Question : Quelles sont les variables explicatives de notre cas ❓

- **Has_heart_disease et Max_heart_rate**
- **Gender et Has_heart_disease**
- **Max_heart_rate et Gender**
- **Seulement Has_heart_disease**

💡

En R, il arrive souvent que deux paquets différents contiennent une fonction qui porte exactement le même nom. Quand cela arrive, R ne sait plus laquelle utiliser. Nous allons donc exécuter une commande qui va permettre, dans notre cas, d'exécuter les bonnes fonctions nécessaires à notre analyse.

👨💻

```
library(conflicted)
conflict_prefer("filter", "dplyr")
conflict_prefer("select", "dplyr")
```

Partie 2 : Vérification de l'existence d'un lien

Nous pouvons, préalablement à la réalisation de la régression logistique, visualiser les relations entre la pathologie cardiaque et les deux variables explicatives. Pour cela, nous créons une variable has_heart_disease_num afin de recoder les modalités de la variable has_heart_disease : « no » en 0 et « yes » en 1, grâce à la fonction mutate().

Nous en profitons aussi pour renommer heart_disease en HD (plus court) :

```
HD <- heart_disease %>%
  mutate(has_heart_disease_num = ifelse(has_heart_disease == "no", 0, 1)) %>%
  mutate(has_heart_disease_num = as.numeric(has_heart_disease_num))
```

Pour visualiser cela, on réalise un scatterplot qui représente le fait d'avoir une maladie cardiaque en fonction de la vitesse de la fréquence cardiaque.

```
ggplot(HD, aes(x = max_heart_rate, y = has_heart_disease_num)) +
  geom_point()
```

Question : Quelle(s) affirmation(s) est/sont correcte(s) ❓

- Avoir une fréquence cardiaque max élevée semble avoir un lien avec le fait d'être porteur de la maladie.
- Avoir une fréquence cardiaque max élevée ne semble pas avoir un lien avec le fait d'être porteur de la maladie.
- Le fait d'avoir une fréquence cardiaque max faible me donne plus de chance d'être porteur d'une maladie cardiaque.
- Le fait d'avoir une fréquence cardiaque max faible me donne plus de chance de ne pas être porteur d'une maladie cardiaque.

Intéressons-nous, à présent, à la relation entre la pathologie cardiaque et le sexe :

```
ggplot(HD, aes(gender, fill = has_heart_disease)) +
  geom_bar(position = "fill", col = "black") +
  scale_fill_manual(values = c("#43d8c9", "#95389e"))
```

Question : Choisis la bonne affirmation.

- Les femmes sont plus exposées au fait d'avoir une maladie cardiaque.
- Les hommes sont plus exposés au fait d'avoir une maladie cardiaque.

Partie 3 : Réalisation de la régression logistique

Pour réaliser une régression logistique avec R, nous utilisons la fonction glm() et l'argument family = binomial.

En écrivant ceci, vous dites à R : "Attention, la colonne has_heart_disease ne contient que deux catégories. Adapte tes calculs pour cela."
En résumé : Sans family = binomial, R ferait des calculs mathématiques inadaptés à une question de type "Oui/Non".

```
mod1 <- glm(has_heart_disease ~ max_heart_rate + gender,
            family = binomial,
            data = HD)
```

Vérification des conditions d'application de la régression logistique

1/ Nombre de cas suffisants

Pour réaliser une régression logistique, il est nécessaire d'avoir un nombre suffisant de données. En pratique, il est recommandé d'avoir au moins 10 fois plus d'événements (d'individus porteurs d'une maladie cardiaque) que de paramètres dans le modèle.

On utilise alors la fonction summary() pour obtenir un résumé de notre modèle :

```
summary(mod1)
```

On peut voir dans la partie "coefficients" de notre résumé qu'il y a 3 lignes (paramètres). Il en faut donc 10 fois plus qui soient porteurs de la maladie (3 x10 = 30).

Vérifions cela grâce à cette fonction :

```
# On veut voir combien on a d'individu malade.
table(HD$has_heart_disease)
```

Question : La règle des 10 est-elle respectée dans cette situation ❓
Combien a-t-on d'individu saint dans notre échantillon ❓

2/ Absence de surdispersion

La surdispersion, c'est quand il y a plus de variabilité (de pagaille) dans vos données réelles que ce que le modèle avait prévu. Si vous ignorez la surdispersion, votre modèle devient arrogant : il va sous-estimer ses marges d'erreur.

Le calcul simple (Le test) :

Pour savoir si votre modèle "ment" sur sa précision, on fait une division toute bête avec deux chiffres que summary() vous donne tout en bas :

$$\text{Ratio} = \frac{\text{Déviance Résiduelle (Le bazar qui reste)}}{\text{Degrés de liberté (La taille de l'échantillon corrigée)}}$$

- *Si le résultat est proche de 1 : Tout va bien, le modèle est honnête.*
- *Si le résultat est trop grand (ex: > 1.5 ou 2) : Il y a surdispersion, le modèle est trop confiant.*

Question : Les données de notre modèle sont-elles exposées à la surdispersion ❓

- Non.

💡

(NB : Dans le cas où le modèle est surexposé à cela, on peut utiliser le paramètre family = quasibinomial, qui est une façon de dire au modèle "Détends-toi, les données sont floues, élargis tes marges d'erreur").

Partie 4 : Interprétation des résultats de la régression logistique

💡

*Les coefficients que l'on peut observer dans la sortie de la fonction summary sont traîtres car il s'agit des **Log Odds** (le logarithme des odds ratio). Ils sont sous cette forme car R les traite mieux de cette manière, mais c'est compliqué pour nous humains. Nous utilisons donc une fonction pour obtenir les odds ratios.*

👨‍💻

```
# Transformation des log odds en odds ratios
exp(coef(mod1))
# Calcul de ses intervalles de confiance :
exp(cbind(OR = coef(mod1), confint(mod1)))
```

💡

Comment lire les Odds Ratios ? Le Concept Clé :

- *OR > 1$: Facteur de Risque (Augmente la maladie).*
- *Très proche de 1 (1.01) : N'a pas d'effet.*
- *OR < 1$: Facteur Protecteur (Diminue la maladie).*
- *(OR-1) x100 = %d'augmentation du risque.*

Concernant les intervalles de confiance :

C'est la "fourchette" de précision. On est sûr à 95% que le vrai Odds Ratio se trouve quelque part entre ces deux bornes.

La Règle d'Or (La Règle du 1) :

- *Si l'intervalle traverse 1 (ex: de 0.8 à 1.2) → Pas significatif (on ne peut rien conclure, l'effet peut être nul).*

- *Si l'intervalle est entièrement au-dessus ou en dessous de 1 → Significatif (l'effet est prouvé).*

```
# Transformation des log odds en odds ratios
exp(coef(mod1))
# Calcul de ses intervalles de confiance :
exp(cbind(OR = coef(mod1), confint(mod1)))
```

*NB: Puisque R a écrit `gendermale`, cela signifie qu'il compare les **Hommes** ("Male") par rapport aux **Femmes***

Question : Vrai ou Faux

1. Un homme a environ 4 fois plus de risques d'être malade qu'une femme (soit une augmentation du risque de 300%).
2. Pour chaque battement de cœur supplémentaire par minute, le risque de maladie baisse de 5%.

Question à choix

- Le genre influence le fait d'avoir une maladie cardiaque.
- Le rythme cardiaque max influence le fait d'avoir une maladie cardiaque.
- Le genre et le rythme cardiaque max influencent le fait d'avoir une maladie cardiaque.
- Aucune de ces 2 variables n'influence le fait d'avoir une maladie cardiaque.

Réaliser une Anova :

Pourquoi utiliser la fonction `Anova()` en plus du `summary()` ?

La fonction `summary()` regarde les détails : elle découpe chaque variable pour comparer les catégories une par une (ex: Groupe B contre Groupe A, Groupe O contre Groupe A...).

- *Le risque : Avec une variable à plusieurs catégories (comme le groupe sanguin), vous vous retrouvez avec plein de Odds ratio différents, ce qui rend difficile de dire si la variable est **globalement** importante.*

*La fonction `Anova()` regarde l'ensemble : elle teste la variable comme un **bloc unique** (ex: "Le Groupe Sanguin" en entier).*

- *L'avantage : Elle vous donne **une seule** réponse **globale** pour vous dire si, oui ou non, cette variable mérite sa place dans le modèle.*

```
Anova(mod1)
```

LR Chisq (La Force) : Il mesure la puissance de l'information apportée par la variable. Plus le chiffre est grand, plus la variable est indispensable au modèle.

Question : Pourquoi l'ANOVA considère-t-elle la fréquence cardiaque comme plus significative que le genre, alors que l'effet visible sur l'Odds Ratio semble beaucoup plus spectaculaire pour le genre ❓

Partie Finale : Mise en forme et visualisation des résultats

Nous avons désormais nos résultats, mais dans un rapport, il faudra toujours illustrer vos propos. Voici quelques options que vous pouvez envisager.

Premier graphique :

```
library(finalfit)
library(knitr)

dependent = "has_heart_disease"
explanatory = c("gender", "max_heart_rate")

# Création du tableau de résultats
res_glm_multi <- HD %>%
  glmmulti(dependent, explanatory) %>%
  fit2df(estimate_suffix = "(multivarié)")

# Affichage propre
res_glm_multi
kable(res_glm_multi, row.names = FALSE, align = c("l", "l", "r", "r", "r", "r"))
```

Second graphique :

```
# Forest Plot :
HD %>%
  or_plot(dependent, explanatory,
          table_text_size = 4,
          title_text_size = 16)
```